Recomendação de Cursos Online para Desenvolvimento Profissional: uma Aplicação de Filtragem Colaborativa e Baseada em Conteúdo

Projeto Aplicado III — Etapa 3: Metodologia

Bruno Cerqueira Gianotti | 10721759
Reginaldo Rogério de Campos | 10743942
Samya Camily de Santana Silva | 10368906

Universidade Presbiteriana Mackenzie

São Paulo, 2026

Sumário

1. Introdução....3
1.1 Contexto do trabalho....3
1.2 Motivação....3
1.3 Justificativa....4
1.4 Objetivo geral....4
1.5 Objetivos específicos....4
1.6 Questões de pesquisa....5
1.7 Objetivo extensionista....6
2. Referencial teórico....7
2.1 Sistemas de recomendação....7
2.2 Filtragem baseada em conteúdo....8
2.3 Filtragem colaborativa....8
2.4 Sistemas híbridos....9
2.5 Avaliação de sistemas de recomendação....10
2.6 Trabalhos relacionados....10
2.7 Usabilidade e avaliação com usuários....12
3. Metodologia....13
3.1 Definição do problema e objetivos....14
3.2 Coleta de dados....14
3.3 Pré-processamento e limpeza dos dados....14
3.4 Divisão dos dados....15
3.5 Seleção e implementação dos algoritmos....16
3.6 Treinamento do modelo....18
3.7 Avaliação do desempenho....19
3.8 Otimização e ajustes....19
3.9 Implantação e monitoramento....20
4. Referências....22

1. Introdução

1.1 Contexto do trabalho

Sistemas de recomendação são hoje um componente central na forma como plataformas digitais conectam usuários a conteúdos relevantes, sendo amplamente utilizados em domínios como comércio eletrônico, streaming de vídeo e música e plataformas de ensino online. No contexto da educação a distância, o crescimento acelerado da oferta de cursos, impulsionado por plataformas como Coursera e Udemy, tornou a curadoria manual de conteúdo inviável, criando a necessidade de mecanismos automatizados capazes de indicar, dentre milhares de opções, os cursos com maior probabilidade de relevância para cada usuário. Esse cenário se conecta diretamente à Agenda 2030 da ONU, em especial aos Objetivos de Desenvolvimento Sustentável (ODS) 4 – Educação de Qualidade e 8 – Trabalho Decente e Crescimento Econômico, uma vez que facilitar o acesso a capacitação adequada tem impacto direto na empregabilidade e no desenvolvimento profissional de milhões de pessoas.

Este projeto propõe o desenvolvimento e a comparação de diferentes técnicas de sistemas de recomendação aplicadas a uma base real de avaliações de cursos da plataforma Coursera, com o objetivo de simular, de forma prática, o problema enfrentado por qualquer pessoa em processo de desenvolvimento profissional: encontrar, em meio a um catálogo extenso, o curso mais adequado ao seu perfil e histórico. O modelo resultante é disponibilizado à comunidade em um site gratuito, o Próximo Curso.

1.2 Motivação

A escolha do tema decorre do interesse do grupo em aprofundar o conhecimento técnico em aprendizado de máquina aplicado a problemas reais de recomendação, aliado à relevância social do problema escolhido. Ajudar pessoas a encontrar o curso certo impacta diretamente sua capacitação profissional e sua inserção ou recolocação no mercado de trabalho, tema especialmente sensível em um cenário de transformação digital acelerada, em que a qualificação constante se tornou condição para a empregabilidade. Também motivou a escolha do tema a

disponibilidade de uma base de dados real, pública e com volume suficiente para permitir uma comparação técnica robusta entre diferentes abordagens de recomendação.

1.3 Justificativa

A relevância do tema se justifica por quatro aspectos. Do ponto de vista social, um sistema de recomendação de cursos bem construído reduz a barreira de acesso à capacitação profissional, ajudando o usuário a navegar por um catálogo extenso e a tomar decisões mais informadas sobre sua trajetória de aprendizado, em contribuição direta aos ODS 4 e 8. Do ponto de vista acadêmico, o projeto permite exercitar, na prática, as técnicas centrais da área (filtragem baseada em conteúdo e filtragem colaborativa), comparando-as de forma objetiva sobre os mesmos dados e propondo uma abordagem híbrida entre ambas. Do ponto de vista de mercado, sistemas de recomendação estão entre as aplicações de aprendizado de máquina mais demandadas, o que confere ao projeto aderência ao mercado de trabalho de tecnologia. Por fim, do ponto de vista dos dados, a base escolhida (Course Reviews on Coursera) apresenta desafios reais e não triviais, como alta taxa de duplicidade de registros, forte concentração das notas e esparsidade da matriz usuário-item, cujo tratamento adequado agrega valor metodológico ao trabalho.

1.4 Objetivo geral

- Desenvolver um sistema de recomendação de cursos online que, a partir do histórico de avaliações e das preferências de uma pessoa, sugira novos cursos com maior probabilidade de relevância para o seu desenvolvimento profissional.

1.5 Objetivos específicos

- Analisar a base de cursos e avaliações da Coursera, identificando suas características, limitações e necessidades de tratamento.
- Preparar os dados por meio da remoção de duplicidades, do tratamento de valores ausentes e da divisão em conjuntos de treino, validação e teste.

- Implementar uma abordagem de recomendação baseada em conteúdo (Content-Based), que use a similaridade textual entre os cursos.
- Implementar uma abordagem de recomendação colaborativa (Collaborative Filtering), que use o padrão de avaliações entre usuários e cursos.
- Combinar as duas abordagens em um modelo híbrido, definindo em uma validação separada o peso de cada técnica e os parâmetros dos modelos.
- Avaliar comparativamente os modelos com as métricas Precision@K, Recall@K e NDCG@K, frente a um baseline de popularidade.
- Disponibilizar o modelo em um site aberto à comunidade e avaliar sua utilidade e sua usabilidade com usuários reais.

1.6 Questões de pesquisa

O problema investigado é como indicar, em um catálogo com centenas de cursos e poucas avaliações por pessoa, os cursos mais relevantes para quem busca se qualificar. A partir dele, o trabalho busca responder às seguintes questões:

- **Q1.** Um modelo híbrido, que combina filtragem colaborativa e filtragem baseada em conteúdo, recomenda cursos com mais acerto do que cada técnica isolada e do que uma recomendação baseada apenas na popularidade dos cursos?
- **Q2.** Qual combinação entre as duas técnicas, e quais parâmetros dos modelos, produzem as melhores recomendações quando escolhidos sem usar os dados de teste?
- **Q3.** Na ausência de uma descrição dos cursos, o texto das avaliações escritas pelos alunos é suficiente para representar o conteúdo de cada curso?
- **Q4.** Disponibilizado como site, o sistema é considerado útil e fácil de usar por pessoas da comunidade?

A hipótese de trabalho é que o modelo híbrido supera tanto as técnicas isoladas quanto o baseline de popularidade, porque cada técnica compensa as limitações da outra (BURKE, 2002).

1.7 Objetivo extensionista

Contribuir para a democratização do acesso à educação e à qualificação profissional, por meio do desenvolvimento de um sistema de recomendação de cursos online que auxilie indivíduos na identificação de oportunidades de aprendizagem alinhadas às suas necessidades, contribuindo para os ODS 4 – Educação de Qualidade e 8 – Trabalho Decente e Crescimento Econômico. Para isso, o modelo é disponibilizado gratuitamente no site Próximo Curso, que faz perguntas simples sobre os interesses e o momento de carreira da pessoa e recomenda cursos em linguagem acessível. O uso do site e a opinião dos usuários são registrados de forma anônima, para que a contribuição à comunidade possa ser medida com dados reais.

2. Referencial teórico

2.1 Sistemas de recomendação

Os sistemas de recomendação têm se consolidado como ferramentas essenciais em plataformas digitais, auxiliando usuários na descoberta de produtos, filmes, músicas, cursos e outros conteúdos relevantes. Essas ferramentas buscam personalizar as sugestões de acordo com as preferências de cada pessoa, aumentando o engajamento e a satisfação (RICCI; ROKACH; SHAPIRA, 2011). Na edição mais recente de sua obra de referência, os mesmos autores reforçam que a área passou a incorporar novos domínios e preocupações, como a avaliação rigorosa e o impacto das recomendações sobre os usuários (RICCI; ROKACH; SHAPIRA, 2022). Em domínios com grande volume de opções — como o catálogo de cursos online explorado neste trabalho — essa personalização deixa de ser um diferencial e passa a ser uma necessidade operacional.

Na educação, o uso desses sistemas cresce junto com a oferta de cursos online. Em revisão sistemática de 98 estudos publicados entre 2015 e 2020, Urdaneta-Ponte, Mendez-Zorrilla e Oleagordia-Ruiz (2021) observaram que a maior parte dos sistemas educacionais recomenda recursos de aprendizagem e cursos, que a filtragem colaborativa é a técnica mais usada, seguida das abordagens híbridas, e que a precisão é a métrica de avaliação mais frequente. Focando especificamente em cursos abertos e massivos (MOOCs), Najmani et al. (2022) analisaram 123 trabalhos publicados entre 2012 e 2022 e concluíram que a recomendação de cursos é a aplicação dominante, presente em cerca de 56% dos estudos, com predomínio das filtragens baseada em conteúdo, colaborativa e híbrida. Esses levantamentos confirmam a relevância do problema tratado neste projeto e a adequação das técnicas escolhidas.

Mais recentemente, Butmeh e Abu-Issa (2024) propuseram um sistema híbrido baseado em atributos para e-learning com foco explícito no problema de cold-start, combinando uma abordagem baseada em conhecimento (knowledge-based) com filtragem colaborativa para identificar usuários semelhantes mesmo na ausência total de avaliações prévias. Os autores reportaram ganho de desempenho em relação a

sistemas de cold-start existentes. O trabalho reforça a importância de tratar o problema de partida a frio em sistemas colaborativos.

Em conjunto, esse referencial posiciona o presente projeto na interseção entre a literatura clássica de sistemas de recomendação (filtragem colaborativa, baseada em conteúdo e híbrida) e a literatura mais recente e específica de recomendação de cursos online, fornecendo tanto a fundamentação teórica para as decisões técnicas tomadas quanto um parâmetro de comparação para a discussão dos resultados obtidos.

2.2 Filtragem baseada em conteúdo

A filtragem baseada em conteúdo (Content-Based) recomenda itens com atributos semelhantes aos que o próprio usuário avaliou bem no passado. Lops, de Gemmis e Semeraro (2011) descrevem essa abordagem como o casamento entre os atributos de um perfil de usuário e os atributos de cada item, o que a torna fortemente dependente da qualidade da representação do item. Sua principal vantagem é não depender do comportamento de outros usuários: um item pode ser recomendado mesmo que poucas pessoas o tenham avaliado. Sua principal limitação é a tendência à superespecialização, isto é, a recomendar sempre itens muito parecidos com os já conhecidos.

Quando os itens são descritos por texto, a representação mais usada é o TF-IDF (Term Frequency – Inverse Document Frequency), que atribui a cada termo um peso proporcional à sua frequência no documento e inversamente proporcional à quantidade de documentos em que aparece (SALTON; BUCKLEY, 1988). Assim, termos que caracterizam um item específico recebem peso alto, e termos comuns a todos recebem peso baixo. A semelhança entre dois itens é então medida pela similaridade do cosseno entre seus vetores, que compara a direção dos vetores e não o seu tamanho, evitando favorecer itens com textos mais longos.

2.3 Filtragem colaborativa

A filtragem colaborativa (Collaborative Filtering) parte do princípio de que pessoas que concordaram no passado tendem a concordar no futuro. Em vez de olhar o conteúdo, ela usa a matriz de avaliações entre usuários e itens. Sarwar et al. (2001)

propuseram a variante item-based, que calcula a similaridade entre itens a partir das notas que eles receberam das mesmas pessoas, e mostraram que ela escala melhor em bases grandes, porque a similaridade entre itens é mais estável e pode ser calculada com antecedência. Essa foi a variante adotada no modelo colaborativo deste projeto. A busca pelos k vizinhos mais próximos (KNN) é a forma mais direta de implementar essa ideia.

Apesar de simples, os métodos baseados em vizinhança continuam competitivos. Ferrari Dacrema et al. (2021) tentaram reproduzir algoritmos de recomendação baseados em redes neurais publicados em conferências de destaque e verificaram que 11 dos 12 que puderam ser reproduzidos eram superados por métodos conceitualmente simples, como os de vizinhos mais próximos, quando estes eram bem ajustados. A principal limitação da filtragem colaborativa é o problema de partida a frio (cold-start): ela não consegue recomendar para usuários, nem a partir de itens, sem histórico suficiente de avaliações.

2.4 Sistemas híbridos

Burke (2002) sistematizou as formas de combinar técnicas de recomendação e mostrou que sistemas híbridos tendem a superar os modelos isolados, justamente porque uma técnica compensa as fraquezas da outra: a abordagem por conteúdo não sofre com a falta de avaliações, e a colaborativa não depende da qualidade da descrição dos itens. Entre as formas de combinação descritas pelo autor está a ponderada (weighted), em que as pontuações de cada técnica são somadas com pesos definidos, que é a forma adotada neste trabalho.

No domínio de cursos online, Wu e Liu (2023) propuseram um algoritmo híbrido para MOOCs, avaliado com dados de avaliações da Coursera, que agrupa os alunos, aplica filtragem colaborativa em cada grupo e incorpora atributos dos cursos e a capacidade de cada aluno, com pesos ajustados por experimentação. Os autores relatam desempenho superior aos algoritmos de referência em precisão, revocação e F1. O trabalho reforça a vantagem da combinação de fontes de informação, mas depende de atributos dos cursos que a base usada neste projeto não possui.

2.5 Avaliação de sistemas de recomendação

Zangerle e Bauer (2022), em revisão sobre o tema, destacam que a avaliação de um sistema de recomendação depende de escolhas que precisam ser explicitadas: como os dados são divididos, quais métricas são usadas, com quais referências o modelo é comparado e se a avaliação é feita com dados históricos (offline) ou com usuários reais (online). Na avaliação offline de listas de recomendação (Top-K), as métricas mais comuns são a Precision@K, que mede a fração dos K itens recomendados que eram relevantes, e a Recall@K, que mede a fração dos itens relevantes que apareceram entre os K recomendados.

Essas duas métricas não consideram a ordem da lista: acertar na primeira ou na quinta posição vale o mesmo. O NDCG (Normalized Discounted Cumulative Gain), proposto por Järvelin e Kekäläinen (2002), resolve essa limitação ao dar a cada acerto um peso que diminui com a posição na lista (1/log2(posição + 1)) e dividir o resultado pelo melhor valor possível, de modo que a métrica varia de 0 a 1. Como as pessoas tendem a olhar primeiro os itens do topo, o NDCG aproxima melhor a experiência real de uso.

Dois cuidados metodológicos são destacados na literatura recente. O primeiro é a escolha de baselines fortes: Ferrari Dacrema et al. (2021) mostraram que comparações com referências fracas ou mal ajustadas levam a conclusões otimistas sobre novos métodos. O segundo é o vazamento de dados (data leakage): Ji et al. (2023) mostraram que, quando a divisão entre treino e teste não respeita a ordem do tempo, os modelos aprendem com informações do futuro, o que distorce as métricas e pode até inverter a comparação entre modelos. Ambos os cuidados orientaram os ajustes feitos nesta etapa (seção 3.8).

2.6 Trabalhos relacionados

O trabalho mais próximo deste projeto é o de Mohammed e Hamad (2024), que desenvolveram um sistema de recomendação para dados educacionais massivos usando a mesma base pública de avaliações de cursos da Coursera, em um recorte diferente, e compararam os algoritmos KNN e SVD (Singular Value Decomposition). Os autores obtiveram taxas de acerto (hit rate) de até 96%, o que confirma a

adequação do KNN para essa base. Por outro lado, avaliaram o modelo com métricas de classificação e de erro de previsão de nota (acurácia, RMSE e MAE), e não com métricas de ranking sobre todo o catálogo, o que impede a comparação direta dos valores obtidos com os deste trabalho.

O Quadro 1 resume os trabalhos relacionados e posiciona este projeto em relação a eles. Em comparação com os estudos analisados, este trabalho se diferencia por três escolhas: (i) usa o texto das avaliações como representação do conteúdo dos cursos, na ausência de descrições; (ii) avalia listas de recomendação com métricas de ranking (incluindo o NDCG), com divisão temporal dos dados, escolha de parâmetros em validação separada e comparação com um baseline de popularidade; e (iii) disponibiliza o modelo à comunidade e avalia sua usabilidade com pessoas reais.

Quadro 1 – Trabalhos relacionados e posicionamento deste projeto

Trabalho	Dados	Técnicas	Avaliação	Contribuição e limitação
Urdaneta-Ponte, Mendez-Zorrilla e Oleagordia-Ruiz (2021)	Revisão de 98 estudos (2015 a 2020)	Colaborativa é a mais usada, seguida das híbridas	Precisão é a métrica mais frequente	Mapeia a recomendação na educação; muitos estudos não informam a plataforma usada
Najmani et al. (2022)	Revisão de 123 estudos sobre MOOCs (2012 a 2022)	Conteúdo, colaborativa, híbrida e aprendizado profundo	Não compara métricas entre os estudos	Mostra que recomendar cursos é a aplicação dominante; pouca discussão sobre avaliação
Wu e Liu (2023)	Avaliações de cursos da Coursera	Híbrido: agrupamento de alunos, colaborativa e atributos dos cursos	Precisão, revocação, F1 e MAE	Combina várias fontes de informação; depende de atributos dos cursos e de pesos ajustados
Mohammed e Hamad (2024)	Avaliações da Coursera (Kaggle), outro recorte	KNN e SVD	RMSE, MAE, hit rate, acurácia e revocação	Confirma o KNN nesta base; métricas de classificação, não de ranking
Este trabalho	519.886 avaliações de 623 cursos da Coursera (Kaggle)	TF-IDF, KNN item-based e híbrido ponderado	Precision, Recall e NDCG @5 e @10; validação separada; baseline de popularidade; SUS	Usa o texto das avaliações como conteúdo; disponibiliza o modelo à comunidade em um site

Fonte: elaborado pelos autores (2026).

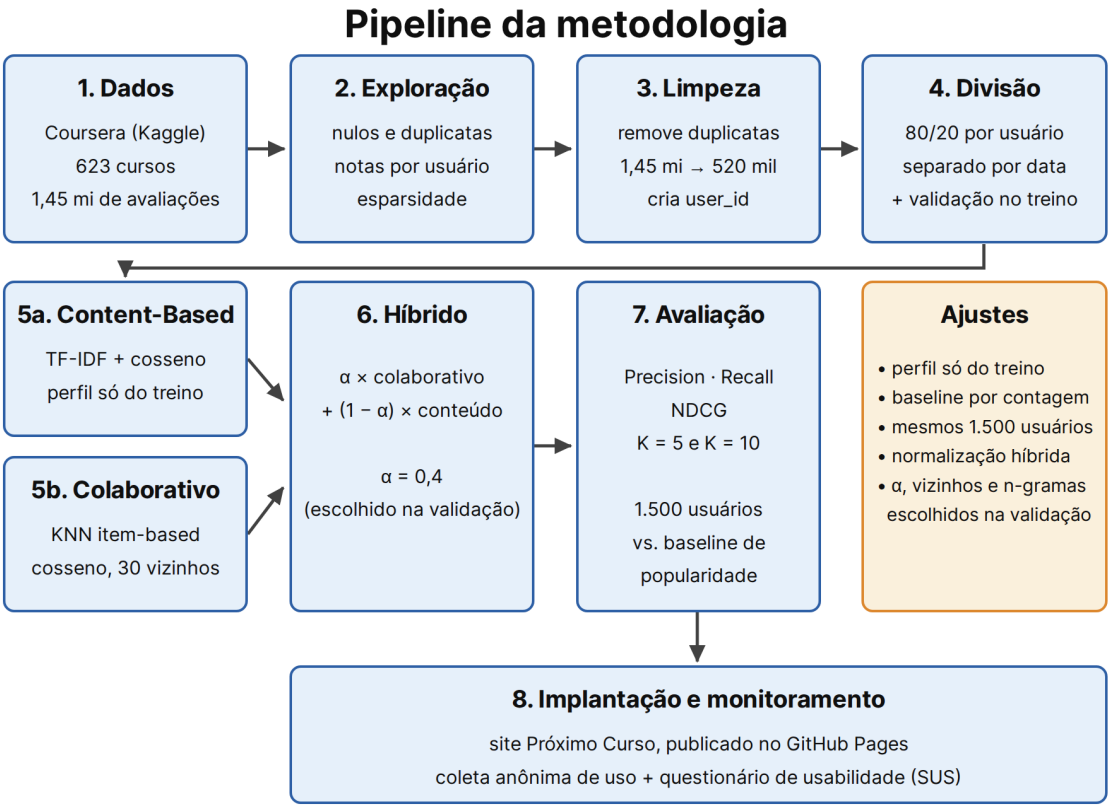
2.7 Usabilidade e avaliação com usuários

Métricas offline indicam se o modelo acerta, mas não se as pessoas conseguem usar o sistema. Para medir a usabilidade, um dos instrumentos mais difundidos é a System Usability Scale (SUS), criada por Brooke (1996): um questionário de dez afirmações, alternadamente positivas e negativas, respondidas em escala de 1 (discordo totalmente) a 5 (concordo totalmente), que resulta em uma pontuação de 0 a 100. Em revisão sobre os 30 anos do instrumento, Lewis (2018) destaca sua confiabilidade, sua independência de tecnologia e a existência de valores de referência, sendo 68 a média usualmente adotada. Bangor, Kortum e Miller (2009) associaram faixas da pontuação a adjetivos, o que facilita a interpretação dos resultados por um público não especialista. A SUS foi escolhida para avaliar o site deste projeto por ser curta, gratuita e comparável com outros estudos.

3. Metodologia

Nesta seção é apresentado o desenvolvimento do trabalho, descrevendo a metodologia utilizada para a execução dos experimentos e para a disponibilização do sistema. O esquema geral da metodologia é apresentado na Figura 1, e as próximas subseções detalham cada etapa. Todo o código foi desenvolvido em Python, em notebook do Google Colab, e está disponível, junto com o site e os dados de configuração, no repositório público do projeto no GitHub: https://github.com/BrunoCerqueiraGianotti/proximo-curso.

Figura 1 – Metodologia utilizada no projeto



Fonte: elaborado pelos autores (2026).

As etapas 1 a 4 preparam os dados; as etapas 5 e 6 constroem os modelos; a etapa 7 avalia o desempenho; o bloco de ajustes reúne as correções e otimizações feitas a partir dos resultados da prova de conceito da Etapa 2; e a etapa 8 leva o modelo à comunidade e acompanha o seu uso.

3.1 Definição do problema e objetivos

O problema foi definido como uma tarefa de recomendação Top-K: dado o histórico de avaliações de uma pessoa, ordenar os cursos que ela ainda não fez e sugerir os K primeiros. Um curso é considerado relevante para a pessoa quando ela o avaliou com nota 4 ou 5. A tarefa foi escolhida por corresponder ao uso real de um recomendador, em que a pessoa vê uma lista curta de sugestões, e não uma previsão de nota para cada curso. Os objetivos e as questões de pesquisa estão descritos nas seções 1.4 a 1.6; a metodologia foi desenhada para respondê-las: as questões Q1 a Q3 são respondidas pela avaliação offline (seções 3.7 e 3.8) e a questão Q4, pela avaliação com usuários do site (seção 3.9).

3.2 Coleta de dados

A base utilizada é a Course Reviews on Coursera, disponibilizada publicamente no Kaggle (MUHAMMAD, [s.d.]). Ela é composta por dois arquivos ligados pela chave course_id: Coursera_courses.csv, com 623 cursos (nome, instituição ofertante, link e identificador), e Coursera_reviews.csv, com 1.454.711 avaliações coletadas entre agosto de 2015 e outubro de 2020, cada uma com o texto da avaliação, o nome digitado pelo avaliador, a data e a nota de 1 a 5. São dados públicos, sem informações pessoais além do nome informado pelo próprio avaliador, que é substituído por um código numérico no pré-processamento.

O carregamento é feito pelo próprio notebook, que tenta, nesta ordem, baixar a base diretamente do Kaggle pela biblioteca kagglehub, receber os arquivos por upload manual ou lê-los da pasta local. Isso permite que qualquer pessoa reproduza o pipeline completo sem passos manuais.

3.3 Pré-processamento e limpeza dos dados

Antes de qualquer modelagem, foi feita uma análise exploratória para conhecer a estrutura dos dados: tamanho das tabelas, valores nulos, linhas duplicadas, distribuição das notas, número de avaliações por usuário e por curso e consistência entre as duas tabelas. A análise mostrou que 64% das linhas de avaliações eram duplicatas exatas, provavelmente um efeito do processo de coleta; que as notas são

muito concentradas (78% das avaliações têm nota 5 e a média geral é 4,7); que todas as avaliações se referem a cursos presentes na tabela de cursos; e que 604 dos 623 cursos têm ao menos uma avaliação.

Com base nesses achados, o pré-processamento executa, nesta ordem: (1) remoção das duplicatas exatas; (2) descarte das 61 avaliações sem texto restantes, já que o texto é essencial ao modelo de conteúdo; (3) padronização do nome do avaliador, removendo o prefixo "By" e espaços extras; (4) conversão da data para o formato de data; e (5) criação de um identificador numérico para cada avaliador. Ao final restam 519.886 avaliações de cerca de 283 mil usuários. A base não possui um identificador único de usuário, apenas o nome digitado, e por isso pessoas homônimas podem ser tratadas como uma só, limitação registrada no trabalho. A matriz de avaliações entre usuários e cursos no treino tem apenas 0,24% das posições preenchidas, cerca de 72% dos usuários fizeram uma única avaliação e as notas se concentram nas faixas 4 e 5, o que limita o sinal disponível tanto para o KNN colaborativo quanto para o perfil de interesses do Content-Based.

A base também não traz uma descrição dos cursos. Para o modelo de conteúdo, cada curso é representado pelo conjunto das avaliações escritas sobre ele, concatenadas em um único texto (perfil textual). Os 19 cursos sem nenhuma avaliação no treino são representados pelo próprio nome.

3.4 Divisão dos dados

A divisão entre treino e teste é feita por usuário e respeita a ordem do tempo: as avaliações de cada pessoa são ordenadas pela data, os 80% mais antigos formam o treino e os 20% mais recentes formam o teste, garantindo ao menos uma avaliação no treino. Assim, o modelo aprende com o passado e é testado na previsão do que a pessoa fez depois, o que evita o vazamento de informações do futuro apontado por Ji et al. (2023). O resultado são 419.841 avaliações de treino e 100.045 de teste.

Para escolher os parâmetros sem usar o teste, a mesma regra é aplicada dentro do treino: os 20% mais recentes do treino de cada pessoa formam a validação (51.675 avaliações), e o restante forma o treino de ajuste (368.166 avaliações). O teste é usado uma única vez, na avaliação final. Como avaliar todos os usuários seria lento,

a avaliação usa uma amostra fixa de 1.500 usuários (semente aleatória 42) entre os que têm ao menos um curso bem avaliado no treino e um curso relevante no conjunto avaliado; a mesma amostra é usada para todos os modelos.

3.5 Seleção e implementação dos algoritmos

Com base no referencial teórico, foram implementadas duas técnicas complementares e uma combinação entre elas:

- **Modelo baseado em conteúdo:** o perfil textual de cada curso é transformado em um vetor TF-IDF, sem as palavras sem significado do inglês (stopwords), e a semelhança entre todos os pares de cursos é calculada pelo cosseno. A pontuação de um curso para uma pessoa é a soma de suas similaridades com os cursos que ela avaliou com nota 4 ou 5.
- **Modelo colaborativo:** é montada uma matriz esparsa curso × usuário com as notas do treino, e um KNN com distância do cosseno encontra, para cada curso, os cursos mais parecidos no padrão de notas. A pontuação de um curso é a soma das similaridades (1 − distância) com os cursos bem avaliados pela pessoa, considerando apenas os vizinhos de cada um.
- **Modelo híbrido ponderado:** as pontuações dos dois modelos são levadas à escala de 0 a 1 (normalização min-max) e combinadas como α × colaborativo + (1 − α) × conteúdo. Quando um dos modelos não gera pontuação para a pessoa, o híbrido usa apenas o outro (fallback), o que reduz o efeito da partida a frio.

Como referência, foi usado um baseline de popularidade que recomenda a todos os cursos com mais avaliações no treino, excluindo os que a pessoa já fez. O Quadro 2 apresenta as bibliotecas Python utilizadas, a função de cada uma e o motivo da escolha, e o Quadro 3 resume os parâmetros dos modelos.

Quadro 2 – Bibliotecas utilizadas: função e justificativa da escolha

Biblioteca	Função no projeto	Por que foi escolhida
os (nativa do Python)	Localiza os arquivos CSV nas pastas do ambiente, inclusive na estrutura de subpastas criada pelo download do Kaggle.	Já vem com o Python, sem instalação. Torna o carregamento independente do ambiente (Google Colab ou computador local).

Biblioteca	Função no projeto	Por que foi escolhida
pickle (nativa do Python)	Salva em disco os modelos já treinados (matriz de similaridade e modelo KNN) e os recarrega na etapa de avaliação.	Já vem com o Python e grava qualquer objeto em arquivo. Evita retreinar os modelos a cada execução, o que economiza tempo com uma base deste tamanho.
pandas	Leitura dos CSV, remoção de duplicatas e nulos, conversão de datas, agrupamentos (reviews por curso e por usuário) e divisão treino/teste.	Padrão de mercado para dados em formato de tabela. Processa as 1,45 milhão de linhas em segundos e se integra diretamente ao scikit-learn.
numpy	Cálculos numéricos: médias de Precision@K, Recall@K e NDCG@K e normalização dos scores (min-max) no modelo híbrido.	É a base numérica sobre a qual pandas, scikit-learn e scipy funcionam. Faz operações sobre vetores inteiros de uma vez, com rapidez.
kagglehub	Baixa o dataset diretamente do Kaggle pelo próprio código do notebook.	Biblioteca oficial do Kaggle. Garante a reprodutibilidade: qualquer pessoa executa o notebook e obtém a mesma base, sem download manual.
scipy (csr_matrix)	Armazena a matriz item × usuário (604 cursos × cerca de 283 mil usuários) guardando apenas as células que possuem nota.	A matriz tem apenas 0,24% de células preenchidas. Em formato comum teria cerca de 171 milhões de posições (≈1,4 GB de memória), quase todas zero. O formato esparso resolve isso e é aceito diretamente pelo KNN.
scikit-learn (TfidfVectorizer)	Transforma o texto de cada curso em um vetor numérico com pesos TF-IDF, removendo palavras sem significado (stopwords) e limitando o vocabulário.	Implementação consolidada e otimizada. Já traz a lista de stopwords em inglês (idioma das reviews) e parâmetros (max_features, min_df) para reduzir ruído.
scikit-learn (cosine_similarity)	Calcula a similaridade entre todos os pares de cursos no modelo Content-Based.	O cosseno compara a direção dos vetores, não o tamanho. Assim, cursos com muitas reviews (textos mais longos) não são favorecidos só pelo volume de texto.
scikit-learn (NearestNeighbors)	Encontra, para cada curso, os 30 cursos mais parecidos no padrão de notas dos usuários (KNN item-based).	Permite usar a métrica de cosseno e trabalha direto sobre a matriz esparsa. O KNN já foi validado para esta mesma base por Mohammed e Hamad (2024).

Fonte: elaborado pelos autores (2026).

Priorizou-se um conjunto enxuto de bibliotecas de código aberto, amplamente documentadas, o que facilita a reprodução do trabalho. A modelagem foi

concentrada no scikit-learn (PEDREGOSA et al., 2011), que reúne as três peças centrais do projeto (vetorização de texto, cálculo de similaridade e busca de vizinhos) com a mesma interface. A biblioteca scikit-surprise, específica para recomendação, foi considerada e descartada, porque seu foco é a previsão de notas e ela não oferece vetorização de texto, necessária ao modelo de conteúdo.

Quadro 3 – Parâmetros dos modelos e da avaliação

Componente	Parâmetro	Valor adotado	Justificativa
TF-IDF	stop_words; max_features; min_df	inglês; 5.000; 2	As avaliações são em inglês; limitar o vocabulário e ignorar termos de um só curso reduz ruído
TF-IDF	ngram_range	(1, 1): só palavras	Pares de palavras (1, 2) foram testados na validação e não melhoraram o resultado
Conteúdo	similaridade	cosseno	Não favorece cursos com textos mais longos
KNN	metric; n_neighbors	cosseno; 30 vizinhos	10, 20 e 30 vizinhos testados na validação; 30 teve o melhor NDCG@10
Relevância	nota mínima	4	Notas 4 e 5 indicam que a pessoa gostou do curso
Híbrido	α (peso do colaborativo)	0,4	Testado de 0 a 1, em passos de 0,1, na validação
Híbrido	normalização	min-max, depois de tirar os cursos já feitos	Coloca as duas pontuações na mesma escala sem distorção pelos cursos já feitos
Avaliação	K; usuários; semente	5 e 10; 1.500; 42	Listas curtas, como as exibidas no site; amostra fixa e reproduzível
Avaliação	critério de escolha	NDCG@10	Considera a ordem da lista

Fonte: elaborado pelos autores (2026).

3.6 Treinamento do modelo

O treinamento usa exclusivamente o conjunto de treino (ou o treino de ajuste, durante a validação). No modelo de conteúdo, o perfil textual de cada curso é construído apenas com avaliações do treino, e o vocabulário e os pesos do TF-IDF são aprendidos sobre esses perfis. No modelo colaborativo, a matriz de notas e o índice de vizinhos são construídos apenas com notas do treino. A matriz de similaridade entre cursos e o modelo KNN são calculados uma única vez e reaproveitados para todas as pessoas, o que torna a recomendação rápida. Para a

avaliação final, os modelos são treinados novamente com o treino completo, usando a configuração escolhida na validação.

3.7 Avaliação do desempenho

Para cada pessoa da amostra, o modelo gera uma lista ordenada de cursos que ela ainda não fez, e a lista é comparada aos cursos que ela avaliou com nota 4 ou 5 no conjunto avaliado (validação ou teste). São calculadas, para K = 5 e K = 10, as métricas Precision@K, Recall@K e NDCG@K, descritas na seção 2.5, e é tirada a média entre as pessoas. São comparados quatro modelos: o baseline de popularidade, o modelo de conteúdo, o colaborativo e o híbrido. Como as diferenças entre configurações próximas podem ser pequenas, a comparação final entre o híbrido escolhido e o híbrido da versão anterior usa um bootstrap pareado, com 2.000 reamostragens dos mesmos usuários, para verificar se a diferença observada é consistente ou se pode ser fruto do acaso. Os valores obtidos serão apresentados e discutidos na seção de Resultados, na Etapa 4.

3.8 Otimização e ajustes

A análise dos resultados da prova de conceito da Etapa 2 mostrou que, antes de melhorar o modelo, era preciso corrigir a forma de medir. O Quadro 4 descreve os ajustes feitos nesta etapa, o problema que cada um resolve e o que foi alterado no pipeline.

Quadro 4 – Ajustes realizados no pipeline na Etapa 3

Ajuste	Problema identificado	O que foi feito
1. Perfil textual só com o treino	O texto de cada curso incluía avaliações do conjunto de teste (vazamento de dados)	O perfil passou a ser montado apenas com avaliações do treino
2. Baseline por número de avaliações	O baseline ordenava por nota média, mas quase todos os cursos têm nota perto de 4,7, o que o tornava fraco demais	O baseline passou a recomendar os cursos com mais avaliações no treino, uma referência mais exigente
3. Mesma amostra para todos os modelos	O baseline era avaliado com 1.500 usuários e os modelos com 1.468	Todos os modelos passaram a usar os mesmos 1.500 usuários
4. Normalização depois de tirar os cursos já feitos	Cursos já feitos ocupavam o topo da escala 0 a 1 e comprimiam a dos demais	Os cursos já feitos são removidos antes da normalização min-max

Ajuste	Problema identificado	O que foi feito
5. Escolha dos parâmetros em validação separada	O peso α havia sido fixado em 0,6 sem teste e, depois, escolhido olhando o próprio teste	α, número de vizinhos e uso de pares de palavras passaram a ser escolhidos em uma validação separada; o teste é usado uma única vez
6. Novas métricas	Precision@5 e Recall@5 não consideram a ordem da lista	Inclusão do NDCG, de K = 10 e de um teste de significância (bootstrap pareado)

Fonte: elaborado pelos autores (2026).

A busca de parâmetros testou, na validação, todas as combinações entre TF-IDF com palavras isoladas ou com palavras e pares de palavras (1-2 gramas), 10, 20 ou 30 vizinhos no KNN e α de 0 a 1, em passos de 0,1. O critério de escolha foi o NDCG@10, por considerar a ordem da lista e uma lista um pouco maior que a exibida inicialmente no site. A configuração escolhida foi α = 0,4, com 30 vizinhos e TF-IDF com palavras isoladas, e é a que está em uso no site.

3.9 Implantação e monitoramento

Para cumprir o objetivo extensionista, o modelo foi disponibilizado no site Próximo Curso (https://brunocerqueiragianotti.github.io/proximo-curso/), publicado gratuitamente pelo GitHub Pages. O site faz até cinco perguntas simples (o que a pessoa quer aprender ou quais áreas a interessam, seu momento de carreira, seu nível e o idioma preferido) e permite marcar cursos já feitos. Os dados do modelo são calculados em Python, com todas as avaliações limpas e a configuração escolhida na validação, e incorporados à página; o híbrido é executado no próprio navegador, sem servidor. Cada sugestão mostra o motivo da indicação, e a pessoa pode pedir mais cursos parecidos ou descartar uma sugestão, o que atualiza a lista na hora. A página inicial apresenta as 12 áreas cobertas pelo catálogo e quantos cursos há em cada uma, já que a base tem mais cursos em algumas áreas do que em outras.

No site foi acrescentada uma regra de qualidade que não faz parte da avaliação offline: vizinhos colaborativos com similaridade menor que 0,05 são desconsiderados. Esses vizinhos aparecem em cursos com poucas avaliações e surgem de apenas uma ou duas pessoas em comum; depois da normalização min-max, uma ligação tão fraca podia virar a pontuação máxima e gerar

recomendações sem relação com o curso marcado. A regra foi adotada para garantir recomendações mais coerentes para quem usa o site.

O monitoramento é feito por uma coleta anônima, enviada a uma planilha do Google por meio de um script (Google Apps Script). São registrados os eventos de uso (recomendações exibidas, cliques para abrir um curso, pedidos de cursos parecidos e descartes), uma nota de 1 a 5 sobre a utilidade das recomendações, um comentário opcional, o questionário SUS e a intenção de fazer algum dos cursos sugeridos. Não são coletados nome, e-mail ou qualquer dado que identifique a pessoa, e o site informa isso de forma explícita. Um painel público mostra apenas números agregados: visitas, taxa de cliques, nota média, pontuação SUS média e distribuição das respostas.

Os dados coletados serão analisados na Etapa 4 para responder à questão Q4, com os seguintes indicadores: taxa de cliques nas recomendações e sua distribuição por posição na lista, nota média de utilidade, pontuação SUS média e sua classificação segundo Bangor, Kortum e Miller (2009), e proporção de pessoas que pretendem fazer algum curso sugerido.

O repositório do projeto (https://github.com/BrunoCerqueiraGianotti/proximo-curso) reúne, organizados por etapa, os documentos entregues, os notebooks, os scripts de preparação dos dados do site, o código do site e do painel, o script de coleta e as instruções para reproduzir todo o trabalho.

4. Referências

BANGOR, A.; KORTUM, P.; MILLER, J. Determining what individual SUS scores mean: adding an adjective rating scale. **Journal of Usability Studies**, v. 4, n. 3, p. 114-123, 2009.

BROOKE, J. SUS: a "quick and dirty" usability scale. In: JORDAN, P. W.; THOMAS, B.; WEERDMEESTER, B. A.; McCLELLAND, I. L. (ed.). **Usability evaluation in industry**. London: Taylor & Francis, 1996. p. 189-194.

BURKE, R. Hybrid recommender systems: survey and experiments. **User Modeling and User-Adapted Interaction**, v. 12, n. 4, p. 331-370, 2002. DOI: https://doi.org/10.1023/A:1021240730564.

BUTMEH, H.; ABU-ISSA, A. Hybrid attribute-based recommender system for personalized e-learning with emphasis on cold start problem. Frontiers in Computer Science, v. 6, art. 1404391, 2024. DOI: https://doi.org/10.3389/fcomp.2024.1404391.

FERRARI DACREMA, M.; BOGLIO, S.; CREMONESI, P.; JANNACH, D. A troubling analysis of reproducibility and progress in recommender systems research. **ACM Transactions on Information Systems**, v. 39, n. 2, p. 1-49, 2021. DOI: https://doi.org/10.1145/3434185.

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. **ACM Transactions on Information Systems**, v. 20, n. 4, p. 422-446, 2002. DOI: https://doi.org/10.1145/582415.582418.

JI, Y.; SUN, A.; ZHANG, J.; LI, C. A critical study on data leakage in recommender system offline evaluation. **ACM Transactions on Information Systems**, v. 41, n. 3, p. 1-27, 2023. DOI: https://doi.org/10.1145/3569930.

LEWIS, J. R. The System Usability Scale: past, present, and future. **International Journal of Human-Computer Interaction**, v. 34, n. 7, p. 577-590, 2018. DOI: https://doi.org/10.1080/10447318.2018.1455307.

LOPS, P.; DE GEMMIS, M.; SEMERARO, G. Content-based recommender systems: state of the art and trends. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (ed.). **Recommender systems handbook**. Boston: Springer, 2011. p. 73-105. DOI: https://doi.org/10.1007/978-0-387-85820-3_3.

MOHAMMED, A. A.; HAMAD, M. M. Machine learning techniques and recommender systems for massive educational data. **Journal of University of Anbar for Pure Science**, v. 18, n. 2, p. 231-240, 2024. DOI: https://doi.org/10.37652/juaps.2024.146489.1187.

MUHAMMAD, I. **Course reviews on Coursera**. Kaggle, [s.d.]. Disponível em: https://www.kaggle.com/datasets/imuhammad/course-reviews-on-coursera. Acesso em: 21 out. 2026.

NAJMANI, K.; BENLAHMAR, E. H.; SAEL, N.; ZELLOU, A. A systematic literature review on recommender systems for MOOCs. **Ingénierie des Systèmes d'Information**, v. 27, n. 6, p. 895-902, 2022. DOI: https://doi.org/10.18280/isi.270605.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

RICCI, F.; ROKACH, L.; SHAPIRA, B. Introduction to recommender systems handbook. In: RICCI, F.; ROKACH, L.; SHAPIRA, B.; KANTOR, P. (ed.). **Recommender systems handbook**. Boston: Springer, 2011. p. 1-35. DOI: https://doi.org/10.1007/978-0-387-85820-3_1.

RICCI, F.; ROKACH, L.; SHAPIRA, B. (ed.). **Recommender systems handbook**. 3. ed. New York: Springer, 2022. DOI: https://doi.org/10.1007/978-1-0716-2197-4.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. **Information Processing & Management**, v. 24, n. 5, p. 513-523, 1988. DOI: https://doi.org/10.1016/0306-4573(88)90021-0.

SARWAR, B.; KARYPIS, G.; KONSTAN, J.; RIEDL, J. Item-based collaborative filtering recommendation algorithms. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB, 10., 2001, Hong Kong. **Proceedings** [...]. New York: ACM, 2001. p. 285-295. DOI: https://doi.org/10.1145/371920.372071.

URDANETA-PONTE, M. C.; MENDEZ-ZORRILLA, A.; OLEAGORDIA-RUIZ, I. Recommendation systems for education: systematic review. **Electronics**, v. 10, n. 14, 1611, 2021. DOI: https://doi.org/10.3390/electronics10141611.

WU, B.; LIU, L. Personalized hybrid recommendation algorithm for MOOCs based on learners' dynamic preferences and multidimensional capabilities. **Applied Sciences**, v. 13, n. 9, 5548, 2023. DOI: https://doi.org/10.3390/app13095548.

ZANGERLE, E.; BAUER, C. Evaluating recommender systems: survey and framework. **ACM Computing Surveys**, v. 55, n. 8, p. 1-38, 2022. DOI: https://doi.org/10.1145/3556536.